

Seismic Blind Deconvolution Based on Self-Supervised Machine Learning (SSL-BD)

Applied Sciences, 2024 - mdpi.com

Xia Yin, Wenhao Xu, Zhifang Yang, Bangyu Wu

28 de agosto de 2026

Métodos Avançados de Inteligência Artificial para Processamento de Dados Sísmicos
COPPE - UFRJ

Problema

Arquitetura

Etapa 1

Etapa 2

Etapa 3

Problema

Problema

A ideia básica da deconvolução sísmica é:

$$y = w * r \quad (1)$$

onde:

- y : dado sísmico observado;
- w : wavelet sísmica;
- r : refletividade;
- $*$: convolução

Blind deconvolution é um problema mal-posto e subdeterminado em que w e r são desconhecidos

Por que é um problema difícil?

Supondo que a verdadeira refletividade seja $r = [0, 1, 0, -0.5, 0]$ e a wavelet seja $w = [0.5, 1, 0.5]$;

Dado que convolução produz $y = w * r$, em vez de vermos os dois picos de refletividade diretamente, observamos versões deles "espalhadas" pela wavelet.

Mas como saber se uma determinada estrutura em y veio da wavelet ou da refletividade?

Por exemplo, talvez uma wavelet mais estreita combinada com uma refletividade mais larga produza praticamente o mesmo y .

Métodos existentes

O artigo separa os métodos existentes em três grupos:

1. métodos clássicos;
2. machine learning supervisionado;
3. self-supervised learning.


O problema dos métodos supervisionados é que precisamos de labels de refletividade.

O self-supervised learning tenta contornar isso. O modelo SSL-D usa o próprio modelo físico de convolução dentro da função de perda, mas precisa conhecer a wavelet.

A novidade do SSL-BD é trabalhar com wavelet desconhecida.

Arquitetura

Arquitectura



Etapa 1

O método não começa a rede com uma wavelet completamente aleatória.

Ele tenta obter uma estimativa inicial da wavelet a partir do próprio dado.

Passos:

1. Cálculo da média dos traces $\bar{y} = \frac{1}{N_{traces}} \sum_i y_i$
2. Cálculo da $FFT(\bar{y})$ e espectro de amplitude $|FFT(\bar{y})|$
3. Suavização do espectro de amplitude com um polinômio cúbico local de 7 pontos
4. Aplicação da IFFT ao espectro suavizado

A wavelet inicial (w_0) é calculada como $IFFT(smooth(|FFT(\bar{y})|))$

O método usa a transformada de Hilbert para girar w_0 no domínio de fase por θ

$$w_{pred} = Re[(w_0 + jHilbert(w_0))e^{-j\theta_{pred}}] \quad (2)$$

Etapa 2

O método utiliza uma Residual Neural Network para prever a refletividade:

$$R_{pred} = NN_R(Y_{obs}; \phi_R) \quad (3)$$

onde ϕ_R são os parâmetros da rede.

A arquitetura possui:

- residual blocks;
- convoluções;
- LeakyReLU;
- long skip connections.

Para o primeiro bloco, o kernel é $29 \times 29 \times 29$ no caso 3D.

Os demais usam $3 \times 3 \times 3$, e a última camada utiliza $1 \times 1 \times 1$

Para o caso 2D, eles simplesmente substituem as convoluções 3D por convoluções 2D.

Etapa 3

A terceira etapa estima a fase θ

$$\theta_{pred} = NN_{\theta}(Y_{obs}; \phi_{\theta}) \quad (4)$$

A arquitetura possui:

- 4 camadas convolucionais;
- 2 fully connected layers.

A primeira convolução usa kernel 29×1 e stride 14.

As seguintes usam 4×1 e stride 2.

Depois ocorre flattening e duas camadas fully connected, culminando em um único valor de fase.

Sumarização do método

O método emprega uma restrição de sparsity relativa, em que o threshold (μ) de sparsity muda durante o treinamento com base em $r_{epoch} = \frac{\text{época atual}}{\text{total de épocas}}$

1. Rede recebe Y_{obs}
2. Rede produz R_{pred} e θ_{pred}
3. Com θ_{pred} , calcula-se w_{pred}
4. Aplica-se sparsity $R_{pred} \rightarrow \bar{R}_{pred}$
5. Faz-se a operação física $\bar{Y}_{pred} = w_{pred} * \bar{R}_{pred}$
6. A perda é calculada como $\mathcal{L} = ||Y_{obs} - \bar{Y}_{pred}||_2^2$